CrowdLocateLab

工程质量审查与加固

故障复现、回归验证与科研证据保全

审查结论

本次审查发现了原测试未覆盖的实际缺陷，并在新运行入口、应用检查和证据浏览界面中加入修复与回归测试。可以报告的是**已检查范围内的结果与剩余限制**；有限测试无法证明程序零缺陷，亦不能保证任意输入的数学正确性或工业部署效果。

本报告对应仓库orgyuanbao/CrowdLocateLab，以已发布基线提交`270b804`为比较起点。原 52 页论文、冻结估计器、模型日志、数据和测试成绩保持原样。新增运行使用`run_research.py`，原入口保留作历史复现。

保持清晰的三条边界

1. **历史科学证据。**两轮共 27 次真实模型调用、25 个研究动作，冻结后共 22,052 次定位计算。这些数字没有因本次检查而增加。
2. **本次工程验证。**采用离线模型夹具、反例输入、恢复与并发测试，复核既有数据和统计结果；没有新增真实模型研究或独立盲测。
3. **数值缺陷处置。**不在旧冻结代码中偷偷替换求解器。新应用层独立筛查并拒绝不稳定输出，原估计与校准仅保留作诊断；这不是对任意退化情形的完整求解。

验证证据入口

完整机器记录保存在`verification/hardening/`。其中`checks.json`记录软件测试、跳过项、环境、两轮历史审计和统计复核；`example_prediction.json`保存新应用入口对项目示例的实际输出。测试总数应以该 JSON 和相应提交的 GitHub Actions 为准，不能把夹具数量当作新科研实验。

首轮工程复核执行 **184 项测试：183 项通过、1 项因符号链接权限跳过、0 项失败**；比原 129 项增加 55 项。Python 3.12.14、NumPy 2.5.4、SciPy 1.18.1。两轮历史审计均为`passed_frozen`，各自零错误、零警告。**进一步复核发现的缺陷、修复与最终验证见第 5 页起的补充记录；上述数字仅属于首轮。**

1 智能体运行与证据完整性

1.1 实际发现及修复

问题	原行为或风险	加固后的处理
无法冻结时停止	规划提示允许停止，工具却拒绝未冻结的 finish，可能无效耗尽预算。	允许记录非空停止理由；保持未冻结，不授权留出评测。
JSON 数字溢出	嵌套参数中的 `1e309` 可变成无穷值，后续日志写入失败。	响应进入成功日志前检查有限值、重复键和序列化；走受预算限制的错误处理。
中断恢复	截短事件日志仍可能恢复；单改状态计数可能影响预算或回放位置。	先核验链尾、初始化身份、状态与工具快照哈希；不完整请求和不确定工具状态拒绝恢复。
回放来源	未验证旧事件内容哈希；来源字节及严格提示模式未完全绑定身份。	验证完整事件链，以内存快照回放；源文件哈希、严格模式写入运行身份。
同目录并发	首次启动或恢复竞争可能写入同一日志。	首次原子创建目录，使用独占运行锁；崩溃遗留锁要求人工检查。

1.2 可恢复不等于任意情况下自动继续

检查点第 2 版绑定`state.json`、工具状态、协议、事件链尾和工具产物目录的字节哈希清单。恢复配置、预算或回放来源改变时拒绝继续。不能自动判断已中断工具的外部副作用是否完成，因此遇到不一致时保留现场，要求核查，而不是重放一个可能已经执行过的操作。

原始两轮目录受新入口保护，且不具有新检查点格式，不能直接冒充新运行恢复。正常退出释放独占锁；进程崩溃的残留锁不能只凭 PID 或时间自动删除。必须先确认原进程已停止、检查证据，再决定后续处理。

1.3 保证的范围

哈希是本地一致性检查，不是数字签名。能够协调改写所有记录与哈希的攻击者不在该保证内。真实模型服务、网络、远程模型版本也没有被这些单元测试固定。新入口沿用已公开的开发协议、种子和先验，明确标记为工程运行，不能宣称新盲测。

2 定位应用的数值可靠性

2.1 两个可复现反例

坐标原点敏感。在确定性的 8 锚点无噪声运动夹具中，将所有位置平移至约 $(500000, 4000000)$ m 附近，冻结求解器仍报告成功，但可能改变模型选择和位置。局部坐标中的误差约 0.003 m，平移后约 6.959 m。这里比较的是同一物理问题，仅坐标原点改变；它揭示数值终止条件对绝对坐标大小的敏感性，不是新性能基准。

弱几何被伪逆截断隐藏。锚点取 $(10, 0), (20, \varepsilon), (30, -\varepsilon)$，目标在原点，使用精确距离。当 ε 从 10^{-3} 降至 10^{-4} 时，数据更接近共线，但原尺度代理却可能从 100 m 降至约 0.577 m。原因是伪逆截断了弱方向；仅按输出半径判断可能错误接受该结果。

2.2 应用层增加独立筛查

`application_safety.py` 从观测与估计独立重算保留样本的数据 Jacobian，检查参数维度、秩、奇异值、优化成功和活动边界。最小与最大奇异值比值必须满足

$$\frac{s_{\min}(J)}{s_{\max}(J)} > 10^{-5}.$$

此外将第一个锚点作为新坐标原点，再作一次**诊断拟合**，比较还原后的点估计、速度和模型选择。位置变化阈值为

$$\tau_x = \max(0.05\,\mathrm{m},\ 10^{-3}L), \qquad \tau_v = \max(0.001\,\mathrm{m/s},\ \tau_x/\max(\Delta t, 1\,\mathrm{s})),$$

其中 L 为中位距离、最大锚点轴跨度和 1 m 中的最大值。这些阈值是公开的工程规则，并非由留出成绩拟合的最优阈值。非零随机子集初始化因依赖绝对观测哈希而保守拒绝；当前两轮冻结方法该配置均为零。

2.3 输出语义和成本

筛查失败时输出`status=rejected_numerical_quality`；第二轮应用的`acceptance.accepted=false`，即使半径很小或用户未提供半径阈值也一样。原点估计、速度、尺度、区域半径保持不变，不能把诊断拟合结果套入旧校准。

额外拟合次数、工作量与耗时单独记录。原论文速度比较不包含该开销。尚未重新评估新筛查后的接受率、定位误差和条件覆盖；通过筛查仍不能排除全局镜像歧义、模型失配、错误传感器标定或分布偏移。

3 接口、浏览器与验证边界

3.1 应用来源与界面容错

输入先读取为单一字节快照，再由同一快照解析与计算哈希，防止求解期间文件变化导致记录的哈希对应另一份输入。第一轮校准读取也绑定相同快照，且校准水平改为精确匹配，不用近似相等冒充同一水平。

研究浏览器对列表代替对象、空对象、非法嵌套结构、重复键、非有限数字和不完整 JSON 增加容错。无效或缺失证据显示不可用，不冒充零误差。已知文件的解析路径必须位于配置范围内；HTTP 接口保持只读且仅绑定本机。界面存储文本使用文本节点或画布显示，不插入可执行 HTML。它仍是本地研究工具，未认证为生产级多用户服务。

3.2 如何复查

在项目根目录安装依赖后执行：

```
python -B verification/hardening/run_checks.py
python -B -m unittest discover -s tests -v
python audit.py --run runs/revision_reference --require-frozen
```

第一个入口运行软件回归、原始两轮审计及既有统计复核；可用`--output`指定不存在的新文件。软件测试包括离线模型夹具和合成反例，不调用真实模型。符号链接测试在缺少 Windows 创建权限时明确跳过，Linux CI 负责执行，不能将跳过写成通过。

本次复核重新计算了既有预测与统计的 123,279 项一致性关系，包括 155 组配对比较与 12 组覆盖总体。它验证已有计算的一致性，没有重新拟合估计器、增加独立样本或创造新模型推理。GitHub 自动检查已覆盖 Windows / Ubuntu 与 Python 3.11 / 3.12，并新增两轮证据审计和统计复核步骤；最终结果需对应本次提交读取。

3.3 仍需诚实保留的限制

- 新主测试静态误差较 WLS 高 29.86%；90% 分组区域实际覆盖为 88.17%；对上一轮总体改善的区间跨零。这些负面结果没有被本次工程加固消除。
- 研究针对工业开放问题的合成数学子问题，没有真实现场数据，不宣称解决完整工业任务，也不宣称算法首次发明。
- 数值核心的历史行为保留；新筛查是拒绝风险输出的保护，并非所有数值缺陷均已根治。
- 有限回归测试、依赖检查与一致性审计都不能推出零漏洞；未来环境变化、未枚举输入和真实模型行为仍需持续验证。

提交建议：原论文、此补充报告、全部代码与原始记录一并保留。课堂展示同时说明实际智能体迭代、负面结论、修复证据和适用范围。

4 进一步复核：证据使用与失败处理

4.1 为什么继续检查

首轮测试通过后，针对“恢复以后实际读到什么”和“工具只完成一部分时如何处理”补充故障注入。发现两个可复现的运行缺陷，以及一项测试统计缺陷。修复位于新增工程层；原始研究控制器、数值核心、两轮运行日志与 52 页论文均保持原样。

4.2 实验记录必须在使用时核验

首轮检查点只绑定状态、工具状态与协议文件，没有覆盖工具状态所引用的实验文件。改动实验 JSON 后，恢复仍可能通过；旧诊断入口还可能返回改动后的误差，同时保留原摘要。这会使后续模型判断依赖与记录不符的数据。

第 2 版检查点增加工具目录的原始字节哈希清单，新增、缺失或改动产物均拒绝恢复。工具调用前核验所引用证据的既有规范化 JSON 摘要；诊断读取一次字节快照，在同一快照上校验和计算，不在校验后重新打开文件。证据路径必须解析在本次运行范围内。

4.3 工具部分完成后失败必须停止

多方法实验可能在第一种方法写完文件后，第二种方法计算失败。原处理将异常反馈给模型继续规划，但内存计数、磁盘状态和已写文件可能已经分离，恢复以后会得到另一种状态。

新增包装层比较调用前后的内存状态、持久状态与产物。异常伴随变更时写入不确定失败标记，控制器保留`pending_tool`并设为`tool_failure_uncertain`，停止后续模型调用并拒绝自动恢复。标记写入失败时仍保留控制器待定状态。验证参数时、尚未产生副作用的普通错误仍可作为观察反馈。已有不完整运行需要人工检查，不能删除标记或重写哈希以冒充一致。

无法建立调用前状态快照时也保守停止；命令行对该不确定失败返回退出码 2，避免调用者误判为正常完成。

4.4 检查点兼容性与信任边界

运行配置中的保护版本更新为 3，检查点格式更新为 2；缺失或旧格式检查点明确拒绝恢复，不静默升级旧记录。新工程运行必须使用新目录。回归覆盖文件篡改、缺失、额外产物、仅格式变化、诊断快照、路径越界、内存或磁盘部分变更、存储故障与正常无副作用错误。

哈希校验用于发现不一致，不能防止具有同等文件写权限的攻击者同时伪造所有证据与摘要，也不是面对任意并发恶意写入的事务文件系统保证。科研结果的可信范围仍需结合完整日志与原始数据理解。

5 统计勘误、数学公式与最终复查

5.1 通过数不能由错误事件数倒推

`unittest` 中的同一测试可产生多个子测试错误。原复核脚本以“运行数减错误数减失败数”计算通过数，在环境权限造成多个子测试报错时出现负数。现改为只在父测试实际成功时计数；失败、错误和跳过仍保留框架的事件数，不能与父测试数直接相减。回归包括多子测试失败、多子测试错误、跳过和预期失败情形。

首次重跑还暴露当前环境对默认临时目录的写入限制。最终复查使用工作区内可写临时目录；环境失败记录保留在本次复核工作目录，没有改写成通过，也没有以缩减测试范围解决权限问题。

5.2 原论文公式的实现勘误

原论文距离残差部分将尺度简写为 $q_i = \sigma_i$。冻结的组合估计器实际先计算尺度，再施加 10^{-5} 的数值下界。因此在`residual=range,scale=reported` 配置下，准确表达为

$$q_i = \max(\sigma_i, 10^{-5}).$$

例如合法输入 $\sigma_i = 10^{-8}$ 时，程序使用 10^{-5}。对于`scale=constant` 且没有显式常量的配置，常量取施加下界后的尺度中位数。该说明仅对应组合估计器的尺度实现，不把其他历史基线一概等同。这里更正文献表述，**没有改变代码、历史拟合值、校准半径或性能成绩**。

5.3 最终验证与记录

最终机器复核记录为`verification/hardening/final_checks.json`，包含软件回归计数、运行环境、两轮完整历史审计、冻结状态和既有统计一致性检查。本轮未调用真实模型、未生成新的科研预测，也没有以软件夹具冒充研究迭代。

本轮 208 项：205 项通过、0 项断言失败、2 项权限错误、1 项跳过，整体仍为未全通过。新增 24 项回归全部通过。两个 HTTP 集成用例在连接本机服务时被当前网络权限以`WinError10013` 拒绝；一项符号链接夹具受系统权限限制。它们没有验证完成，必须在具备权限的环境或对应提交 CI 补验。诊断保存在`verification/hardening/final_software_diagnostics.txt`。

两轮完整历史审计均为`passed_frozen` 且零错误、零警告；冻结检查及 123,279 项统计一致性检查通过。原 52 页论文与冻结研究证据保持原样。

发布状态以相应提交和 GitHub Actions 为准。此补充报告不能单独证明远端已更新，不能用先前提交的绿色状态替代当前提交的检查结果。原论文中的静态退化、覆盖不足、区间跨零以及缺少现场验证等结论继续保留。

结论：复核已发现并修复具体缺陷，同时保留可复查证据和适用边界。有限审查与回归通过不构成“零漏洞”承诺。